


KMeans聚类



什么是聚类任务


- ① 无监督机器学习的一种
- ② 目标将已有数据根据相似度划分到不同的簇
- ③ 簇内样本彼此之间越相似，不同簇的样本之间越不相似，就越好

为什么叫KMeans聚类


- ① 也可以叫K均值聚类
- ② K是最终簇数量，它是超参数，需要预先设定
- ③ 在算法计算中会涉及到求均值

无监督机器学习也是机器学习

是机器学习就涉及到模型求解




KMeans聚类亦是如此



KMeans流程举例


1. Initialise random centroids
2. Until convergence:
 - Assign step
 - Update step
3. End



- ① 随机选择K个簇中心点
- ② 样本被分配到离其最近的中心点
- ③ K个簇中心点根据所在簇样本，以求平均值的方式重新计算
- ④ 重复第2步和第3步直到所有样本的分配不再改变

如何计算样本到中心点的距离


欧氏距离测度 Euclidean Distance Measure



欧氏距离越大，相似度越低

$$euclidean(A, B) = \sqrt{\sum_{i=1}^n (A_i - B_i)^2}$$

余弦距离测度 Cosine Similarity Measure




夹角越大，余弦值越小，相似度越低

$$similarity = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

因为是cosine，所以取值范围是-1到1之间，它判断的是向量之间的方向而不是大小；两个向量有同样的方向那么cosine相似度为1，两个向量方向相对成90°那么cosine相似度为0，两个向量正相反那么cosine相似度为-1，和它们的大小无关。

选择Cosine相似度还是欧氏距离




总体来说，欧氏距离体现数值上的绝对差异，而余弦距离体现方向上的相对差异。

例如，统计两部剧的用户观看行为，用户A的观看向量为 $(0, 1)$ ，用户B为 $(1, 0)$ ；此时二者的余弦距离很大，而欧氏距离很小；我们分析两个用户对于不同视频的偏好，更关注相对差异，显然应当使用余弦距离。



而当我们分析用户活跃度，以登陆次数（单位:次）和平均观看时长（单位:分钟）作为特征时，余弦距离会认为 $(1, 10)$ 、 $(10, 100)$ 两个用户距离很近；但显然这两个用户活跃度是有着极大差异的，此时我们更关注数值绝对差异，应当使用欧氏距离。

cosine相似度更适用于文本



举个例子：

The Three Documents and Similarity Metrics



	Euclidean distance	Cosine Similarity
Doc Sachin & Doc Dhoni	432.4	0.15
Doc Dhoni & Doc Dhoni_small	401.85	0.99
Doc Sachin & Doc Dhoni_small	204.94	0.24

当两篇相似文章长度差距很大、但内容相近时，它们欧氏距离很大，比如两篇文章相同的词'cricket'一个出现100次，另一个出现10次；但它们仍然有一个比较小的夹角，所以这时cosine相似度应用会更合适，更小的夹角，更高的相似度。

归一化后选择谁都一样

如果向量的模长是经过归一化的，可以理解为此时向量被投影到了一个长度为1的球面上，这时欧氏距离和余弦距离有着单调的关系，即

$$\left\| \frac{A}{\|A\|} - \frac{B}{\|B\|} \right\|_2 = \sqrt{2 * (1 - \cos(A, B))}$$

其中 $\left\| \frac{A}{\|A\|} - \frac{B}{\|B\|} \right\|_2$ 表示欧氏距离， $\cos(A, B)$ 表示余弦相似度， $(1 - \cos(A, B))$ 表示余弦距离；在向量的模长归一化的场景下，谁距离最小（相似度最大）就是近邻，那么使用余弦相似度和欧氏距离的查找近邻结果是相同的。

假设二维空间两个点， $A(x_1, y_1)$ $B(x_2, y_2)$

将它们归一化为单位向量后， $\frac{A}{\|A\|} = (\frac{x_1}{\sqrt{x_1^2 + y_1^2}}, \frac{y_1}{\sqrt{x_1^2 + y_1^2}})$ $\frac{B}{\|B\|} = (\frac{x_2}{\sqrt{x_2^2 + y_2^2}}, \frac{y_2}{\sqrt{x_2^2 + y_2^2}})$

$$\cos(\frac{A}{\|A\|}, \frac{B}{\|B\|}) = \frac{x_1}{\sqrt{x_1^2 + y_1^2}} \times \frac{x_2}{\sqrt{x_2^2 + y_2^2}} + \frac{y_1}{\sqrt{x_1^2 + y_1^2}} \times \frac{y_2}{\sqrt{x_2^2 + y_2^2}} \quad (\text{分母是1, 省略})$$


$$euc(\frac{A}{\|A\|}, \frac{B}{\|B\|}) = \sqrt{(\frac{x_1}{\sqrt{x_1^2 + y_1^2}} - \frac{x_2}{\sqrt{x_2^2 + y_2^2}})^2 + (\frac{y_1}{\sqrt{x_1^2 + y_1^2}} - \frac{y_2}{\sqrt{x_2^2 + y_2^2}})^2}$$

$$\text{化简后就是: } euc = \left\| \frac{A}{\|A\|} - \frac{B}{\|B\|} \right\|_2 = \sqrt{2 - 2 \times \cos(\frac{A}{\|A\|}, \frac{B}{\|B\|})} = \sqrt{2 * (1 - \cos(A, B))}$$

注意，上式中向量归一化前和归一化后不影响 $\cos(\theta)$

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{A}{\|A\|} \cdot \frac{B}{\|B\|} = \frac{\frac{A}{\|A\|} \cdot \frac{B}{\|B\|}}{\left\| \frac{A}{\|A\|} \right\| \left\| \frac{B}{\|B\|} \right\|}$$

从几何图形上也比较容易看出来，因为余弦看的是方向，与向量大小无关



KMeans算法目标函数

$$\text{objective function} = \sum_{j=1}^K \sum_{i=1}^n \underbrace{\|x_i^j - c_j\|^2}_{\text{Distance function}}$$

K : number of clusters

n : number of cases


x_i^j : case i

c_j : centroid for cluster

上面的公式既是要去最小化的目标函数，同时也可以作为评价KMeans聚类效果好坏的评估指标。

KMeans算法不保证找到最好的解

事实上，我们随机初始化选择了不同的初始中心点，我们或许会获得不同的结果，就是所谓的收敛到不同的局部最优；这其实也就从事实上说明了目标函数是非凸函数。




一个通常的做法就是运行KMeans很多次，每次随机初始化不同的初始中心点，然后从多次运行结果中选择最好的局部最优解。

KMeans算法K的选择

没有所谓最好的选择聚类数的方法，通常是需要根据不同的问题，人工进行选择。


肘部法则(Elbow method)

改变聚类数K，然后进行聚类，计算损失函数，拐点处即为推荐的聚类数 (即通过此点后，聚类数的增大也不会对损失函数的下降带来很大的影响，所以会选择拐点)




目标法则

如果聚类本身是为了有监督任务服务的（例如聚类产生features【譬如KMeans用于某个或某些个数据特征的离散化】然后将KMeans离散化后的特征用于下游任务），则可以直接根据下游任务的metrics进行评估更好；




KMeans空簇的产生原因


- ① 假设有下面数据



- ② 迭代过程中



- ③ 进一步更新类中心



实时效果反馈

1. 关于KMeans，以下说法不正确的是：

- ☐ A 需要预先指定K值
- ☐ B 可以使用肘部法帮助确定K值
- ☐ C 算法迭代过程中，通过求均值来重新计算K个中心点
- ☐ D 保证可以求得全局最优解

2. 关于距离测度，以下说法不正确的是：

- A 欧氏距离测度是常用的距离测度
- B 余弦距离测度更适用于文本之间计算相似度
- C 样本向量归一化后求欧氏距离数值上等于余弦距离测度
- D 样本向量归一化后求欧氏距离最终效果上等价使用余弦距离测度

答案

1=>D 2=>C