

密度聚类

DBSCAN

Density based clustering

对比KMeans算法

- 1 KMeans尤其容易受到异常值的影响。当算法遍历质心时，在达到稳定性和收敛性之前，离群值对质心的移动方式有显著的影响。
- 2 K-Means只能应用球形簇，如果数据不是球形的，它的准确性就会受到影响。
- 3 最后，KMeans要求我们首先选择希望找到的cluster簇的数量。

DBSCAN不要求我们指定cluster簇的数量，避免了异常值，并且在任意形状和大小的cluster簇中工作得非常好。它没有质心，聚类簇是通过将相邻的点连接在一起的过程形成的。

算法聚类过程

首先，选择一个在其半径内至少有minPts的随机点。

Epsilon (ϵ): 设置的最大半径。

最小点(minPts): 在一个邻域的半径内minPts数的邻域被认为是一个簇。请记住，初始点包含在minPts中。


核心点: 核心数据点，在其近邻距离内至少有minPts个数据点。

然后，对核心点的邻域内的每个点进行评估，以确定它是否在epsilon距离内有minPts (minPts包括点本身)。如果该点满足minPts标准，它将成为另一个核心点，cluster簇将扩展。如果一个点不满足minPts标准，它成为边界点。

边界点: 边界数据点位于郊区，半径区域内需要小于minPts。

随着过程的继续，算法开始发展成为核心点“a”是“b”的邻居，而“b”又是“c”的邻居，以此类推。当cluster簇被边界点包围时，这个聚类簇已经搜索完全，因为在距离内没有更多的点。选择一个新的随机点，并重复该过程以识别下一个簇。

离群点: 这些点不是近邻点，也不是边界点。这些点位于低密度地区。




OPTICS

Ordering Points To Identify Cluster Structure

- 1 这个算法本身核心并不直接划分数据到不同的聚类簇。它仅生成一个关于可达距离（纵轴）图形，然后再去读取这个图形做进一步的聚类。这个图形本质上记录了数据点被处理的顺序（横轴），而不是数据点的具体划分。这是与DBSCAN最大的不同。
- 2 在DBSCAN算法中需要输入两个参数： ϵ 和 $MinPts$ ，选择不同的参数会导致最终聚类的结果千差万别，因此DBSCAN对于输入参数过于敏感。OPTICS算法的提出就是为了帮助DBSCAN算法选择合适的参数，降低输入参数的敏感度。


说白了就是，不像DBSCAN一样，先固定 ϵ ，而是等有了图形之后，就更清晰的能看到如果设置 ϵ 该设置多大了




和 DBSCAN 聚类算法是同一批作者，可认为是改进版。

此算法在DBSCAN聚类上加入了两个新的概念：


核心距离：是确定一个给定点是核心点的半径最小值。如果给定点不是一个核心点，那么它的核心距离是 undefined。




可达距离：定义相对其它数据点 q 。点 p 和 q 之间的可达距离是 p 点的核心距离与 p 和 q 之间的欧氏距离的最大值。注意如果 q 不是一个核心点，可达距离是 undefined。




算法计算流程




1. Calculate core and reachability distances.




2. Update processing order based on distances.




3. Move to the next core point in the processing order.




4. Continue updating and following the processing order.



5. Continue updating and following the processing order.




6. When there are no more neighbors, go to next unvisited case.




得到最终结果

这种聚类方法不同于其它算法就是显示的分割数据到不同簇，而是产生一个关于可达距离的可视化的图形，然后我们可以根据这个能可视化的数据点对应可达距离进行聚类。




不传入 ϵ 自动聚类

上面左图，OPTICS并不需要像DBSCAN一样显示的指定 ϵ 半径，因为OPTICS默认的自动技术(`cluster_method = 'xi'`)，通常默认 $\xi=0.05$ ，这意味着建立一个簇边界可以根据可达距离的陡峭度来建立($1-\xi=0.95$)；或许下面这个图可以更好的帮助理解。



MeanShift



该算法也叫做均值漂移，在目标追踪中应用广泛。本身其实是一种**基于密度的聚类算法**。

主要思路是：计算某一点A与其周围半径R内的向量距离的平均值M，计算出该点下一步漂移（移动）的方向（ $A=M+A$ ）。

当该点不再移动时，其与周围点形成一个类簇，计算这个类簇与历史类簇的距离，满足小于阈值D即合并为同一个类簇，不满足则自身形成一个类簇。直到所有的数据点选取完毕。

原理

给定d维空间中的n个样本点 $x_i (i = 1, \dots, n)$ ，在x点的MeanShift向量的计算基本形式定义为：


$$M_h(x) = \frac{1}{k} \sum_{x_i \in S_h} (x_i - x)$$

其中， S_h 是一个半径为h的高维球区域，k表示n个样本点中有k个点落入区域 S_h 中。非常直观的，MeanShift向量表示区域中k个样本点相对于点x求偏移量再平均。求出来的向量指向概率密度梯度的方向（指向真实质心方向）。

扩展


在扩展的MeanShift中，引入了核函数和权重的概念，相当于给不同的点赋予不同的质量，相当于直觉上在求解这些不同质量分布的点的质心位置。

高斯核函数是一种应用广泛的核函数，因为往往会把不同的簇包含的数据看成是正太分布采样得到的。



$$K\left\{\frac{x - \mu}{\sigma}\right\} = K\left\{\frac{x_i - x}{h}\right\} = \frac{1}{\sqrt{2\pi}h} * \exp\left\{-\frac{(x_i - x)^2}{2h^2}\right\}$$

其中h为bandwidth带宽，其实也就是方差，不同带宽的核函数形式也不一样



由上图可以这样理解，横坐标理解为两变量之间的距离，距离越近（越接近0）则核函数值越大，否则越小。h越大，相同距离的情况下核函数值越小，因此h值作为超参数我们做适当的选择，来满足两变量距离越近，得到权重越大；所以经过核函数改进后的均值漂移，实际上就是加权求平均：

$$M_h(x) = \frac{\sum_{x_i \in S_h} K\left\{\frac{x_i - x}{h}\right\} * (x_i - x)}{\sum_{x_i \in S_h} K\left\{\frac{x_i - x}{h}\right\}}$$

实时效果反馈

1. 关于DBSCAN算法，以下说法不正确的是：

- ☐ A 对异常值不敏感
- ☐ B 可以聚类非线性关系(聚类为任意形状)
- ☐ C 不需要像KMeans那样预先确定cluster簇的数量
- ☐ D 不需要设置半径ε超参数

2. 关于密度聚类算法，以下说法不正确的是：

- ☐ A OPTICS也必须像DBSCAN一样设置超参数ε和MinPts
- ☐ B OPTICS也可以不设置超参数ε就能自动聚类
- ☐ C MeanShift是一种基于密度的聚类算法，不需要提前设置类别数

D MeanShift不仅可以应用于聚类任务，也可以应用于半自动目标检测

答案

1=>D 2=>A